



SusTainable dAta-dRiven manufacTuring

Accordo Innovazione DM 31/12/2021

Prog. n. F/310087/01-05/X56

REPORT DI PRODUCT ANALYSIS

Relazione Parziale N°: RP 6.8

Versione del Documento: RV.1

Data di Revisione del Documento: 30.04.2025

Responsabilità: Gresmalt - Capofila



UNISS
UNIVERSITÀ
DEGLI STUDI
DI SASSARI



UNIVERSITÀ
DELLA
CALABRIA

1.INTRODUZIONE

Negli ultimi anni le organizzazioni industriali hanno progressivamente abbracciato strategie di analisi guidate dai dati per migliorare la propria capacità competitiva nella fornitura di prodotti e servizi. Nel settore ceramico, la crescente varietà e complessità dei portafogli di prodotto rende sempre più arduo individuare modelli di consumo affidabili facendo ricorso a strumenti tradizionali di analisi statistica o a modelli matematici lineari. L'aumento esponenziale del volume di dati disponibili – arricchiti da attributi estetici, strutturali e prestazionali – si accompagna infatti a una scarsità di conoscenza strutturata, che rischia di lasciare inesprese le potenzialità informative insite nelle basi dati aziendali.

L'ipotesi scientifica che orienta la presente attività è che l'eterogeneità intrinseca dei manufatti industriali – espressa dalla coesistenza di variabili quantitative (dimensioni, prestazioni) e qualitative (colore, finiture) – non possa essere adeguatamente rappresentata da modelli che presuppongano omogeneità dei descrittori o adottino esclusivamente metriche euclidee. Tale consapevolezza ha guidato la scelta di ricorrere ad algoritmi specificamente progettati per dataset misti, in grado di preservare sia l'informazione numerica sia quella categoriale.

La baseline originaria dell'attività 6.8, definita in sede progettuale, prevedeva l'impiego dell'algoritmo K-means per suddividere l'inventario prodotti in cluster omogenei (per formato, spessore, colore, tipologia) e successivamente correlare tali segmenti con i dati di vendita. Pur rappresentando un approccio consolidato, questa impostazione iniziale presentava criticità metodologiche significative: da un lato la dipendenza del K-means dalle condizioni iniziali e dalla specificazione a priori del numero di cluster, dall'altro la sua inadeguatezza intrinseca nel trattare variabili categoriali senza ricorrere a trasformazioni arbitrarie che rischiano di distorcere le relazioni originarie.

Da tali considerazioni è scaturita la necessità di riformulare il percorso metodologico, adottando strumenti più coerenti con la natura eterogenea del dataset e capaci di restituire una segmentazione solida, interpretabile e trasferibile in chiave industriale. Gli scopi dell'attività sono stati pertanto ridefiniti lungo tre direttrici principali: i) costruire un dataset strutturato e semanticamente coerente che preservasse la ricchezza informativa originaria, ii) individuare un modello di clustering adatto a gestire simultaneamente variabili numeriche e categoriali, iii) validare i risultati attraverso un sistema multidimensionale capace di misurare la qualità delle partizioni oltre i limiti degli indici tradizionali.

In questo modo, la relazione non si limita a perseguire il risultato quantitativo previsto in fase progettuale – individuare un numero ottimale di cluster – ma introduce un contributo metodologico che mira a garantire robustezza, interpretabilità e trasferibilità dei risultati, ponendo le basi per un utilizzo concreto dei cluster nelle analisi di mercato e nella pianificazione strategica dell'impresa.



2. METODOLOGIA

2.1 Impianto concettuale e motivazione dell'approccio

L'ipotesi scientifica che guida la presente attività muove dalla constatazione che i manufatti industriali si collocano in uno spazio informativo ibrido, in cui coesistono:

- variabili quantitative continue (dimensioni fisiche, parametri prestazionali, indicatori di consumo)
- variabili qualitative discrete (categorie estetiche, finiture superficiali).

Tale eterogeneità non è catturabile in modo soddisfacente da modelli che presuppongono l'omogeneità dei descrittori o che adottano metriche puramente euclidee.

Nel contesto di dati misti, l'applicazione diretta di algoritmi della famiglia k-means può incontrare limiti metodologici noti: sensibilità alle condizioni iniziali (con rischio di convergenze locali subottimali), necessità di specificare a priori il numero di cluster (con potenziali arbitrarietà e instabilità) e trattamento non nativo degli attributi categoriali, che richiederebbero trasformazioni numeriche (ad es. one-hot encoding) con possibili perdite di informazione semantica e distorsioni nelle distanze.

La letteratura metodologica propone estensioni per affrontare queste criticità, tra cui k-modes per dati categorici e k-prototypes per dati misti. In quest'ultimo caso, la dissimilarità tra due osservazioni X e Y è definita come:

$$d(X, Y) = \sum_{i=1}^p (x_i^{\text{num}} - y_i^{\text{num}})^2 + \gamma \cdot \sum_{j=1}^q \delta(x_j^{\text{cat}}, y_j^{\text{cat}})$$

dove:

- $x_i^{\text{num}}, y_i^{\text{num}}$ rappresentano le componenti numeriche;
- $x_j^{\text{cat}}, y_j^{\text{cat}}$ rappresentano le componenti categoriali;
- $\delta(x, y) = 0$ se $x = y$, altrimenti $\delta(x, y) = 1$;
- γ è il parametro di bilanciamento che governa il peso relativo delle due componenti.

Questa formalizzazione consente un trattamento congiunto di caratteristiche numeriche e qualitative, preservando l'interpretabilità dei centroidi (medie per le variabili numeriche; modi per le variabili categoriali).

Sul piano valutativo, il percorso progettuale ha integrato e rafforzato le metriche originariamente considerate introducendo indicatori interni coerenti con la natura non supervisionata del problema (in primis il Silhouette Score), e affiancandovi un framework multidimensionale che amplia la diagnosi oltre la sola componente geometrica. Il Silhouette sintetizza coesione intra-cluster e separazione inter-cluster senza ricorrere a etichette; tuttavia, in presenza di dataset misti, risulta parzialmente indicativo poiché computabile unicamente sulla componente numerica. Da qui l'esigenza di un impianto valutativo più ampio.

2.2 Contestualizzazione e baseline progettuale

L'attività si è sviluppata a partire dalla baseline definita in sede di proposta, che prevedeva:

- l'individuazione di 15–20 cluster
- 20–30 iterazioni per garantire stabilità
- l'uso dell'Accuracy Rate come metrica.

In fase esecutiva, al fine di allineare la valutazione alla natura non supervisionata del problema, si è adottato il Silhouette Score quale indicatore interno primario. L'interpretazione non fa riferimento a soglie “universali”, ma a range qualitativi consolidati in letteratura metodologica: 0,71–1,00 (struttura forte); 0,50–0,70 (struttura ragionevole); 0,26–0,49 (struttura debole), $\leq 0,25$ (assenza di struttura sostanziale). In coerenza con tali range, si è assunto 0,50 come obiettivo operativo di progetto per la selezione e il confronto tra alternative.

Consapevoli delle limitazioni del Silhouette sui dati misti, è stato definito un framework di valutazione multidimensionale (si veda § 2.5) per estendere e rafforzare la diagnosi metodologica.

In parallelo, l'esplorazione del numero di cluster è stata ampliata a [10,25] per coprire in modo più completo le potenziali strutture latenti del portafoglio ceramico.

2.3 Costruzione del dataset e preprocessing

Il dataset è costituito da 13.251 prodotti finiti distinti; per ciascuno sono stati raccolti attributi intrinseci di prodotto (estetici, strutturali, prestazionali) e i volumi di vendita 2017–2024. Per garantire che il clustering riflettesse esclusivamente le caratteristiche intrinseche, i dati di performance commerciale sono stati esclusi dalla partizione e agganciati ex-post ai cluster risultanti.

La complessità informativa (elevata cardinalità di alcune variabili categoriali e distribuzioni sbilanciate) è stata gestita con un preprocessing semanticamente differenziato:

- Variabili ordinali → mapping numerico che preserva l'ordine naturale:
 - Dimensione: PICCOLO (1) → MEDIO (2) → GRANDE (3)
 - Spessore: 7mm (1) → 8mm (2) → 9mm (3) → 20mm (4)
 - Scivolosità R: NPD (1) → R9 (2) → ANTISLIP (3)
 - Colore (intensità cromatica): CHIARO (1) → MEDIO (2) → VARI (3) → SCURO (4)
- Variabili nominali → mantenute categoriali e codificate (label encoding) per l'elaborazione.

Il trattamento delle ordinali è stato orientato a preservare il significato semantico dei livelli. Le ordinali sono state quindi standardizzate (Z-score) per equalizzare i contributi nella componente euclidea della distanza. Nei casi di categorie rare si è proceduto a raggruppamenti

tecnicamente motivati per ridurre il rumore informativo e migliorare leggibilità e stabilità delle soluzioni senza compromettere l'integrità semantica.

2.4 Algoritmo K-Prototypes e ottimizzazione

Per gestire la natura mista del dataset è stato adottato K-Prototypes, che combina una componente euclidea per le variabili numeriche con una componente di simple matching per le variabili categoriali.

Questa impostazione consente di preservare il significato semantico delle variabili categoriali, evitando la distorsione che deriverebbe da codifiche numeriche arbitrarie, e di mantenere al contempo la sensibilità alle variazioni quantitative. I centroidi risultanti sono pertanto direttamente interpretabili: valori medi per le variabili numeriche e valori modali per quelle categoriali, condizione indispensabile per un'analisi che ambisca non solo a distinguere, ma anche a spiegare le classi individuate.

La determinazione del numero ottimale di cluster è stata affrontata mediante una procedura di ottimizzazione sistematica. L'intervallo di ricerca è stato ampliato a [10, 25], rispetto al range inizialmente ipotizzato di 15–20 cluster, al fine di garantire che la granularità emergente fosse effettivamente coerente con la complessità del portafoglio di prodotti. Per ciascun valore di k :

- sono state effettuate repliche multiple di inizializzazione ($n_{init} = 15$ in fase esplorativa, incrementate a 50 nella fase finale),
- sono stati testati due diversi metodi di inizializzazione dei centroidi (Cao e Huang),
- si è applicato come criterio di selezione il Silhouette Score calcolato sulle variabili numeriche (67% del dataset), con soglia operativa pari a 0,5.

Questa strategia ha permesso di ridurre la sensibilità del modello alle condizioni iniziali, uno dei limiti storici della famiglia dei k-means, e di contenere il rischio di "peak hunting" locale nella curva del Silhouette. Inoltre, il ricorso a più schemi di inizializzazione ha migliorato la probabilità di convergere verso soluzioni robuste e non spurie.

Un elemento distintivo dell'implementazione ha riguardato la gestione del parametro γ , delegata alla configurazione automatica di K-Prototypes. Tale scelta, resa possibile dalla standardizzazione preliminare delle variabili numeriche, ha eliminato la necessità di calibrazione manuale iterativa, garantendo un approccio replicabile e meno soggetto a bias soggettivi.

Il protocollo operativo adottato può essere riassunto come segue:

1. fase esplorativa → scansione dell'intervallo [10, 25] con $n_{init} = 15$ e $max_iter = 30$,
2. fase comparativa → confronto sistematico tra inizializzazioni Cao e Huang,
3. fase di ottimizzazione finale → selezione del miglior k sulla base del Silhouette Score, seguita da clustering definitivo con $n_{init} = 50$, $max_iter = 100$ e $random_state$ fissato a 42 per garantire riproducibilità.



2.5 Sistema di valutazione multidimensionale

La valutazione della qualità dei cluster rappresenta un nodo metodologico cruciale in ogni processo di partizionamento non supervisionato. Il Silhouette Score, adottato come indicatore primario, costituisce una metrica ampiamente consolidata in letteratura per la sua capacità di sintetizzare in un unico valore la coesione intra-cluster e la separazione inter-cluster. Nonostante i suoi pregi, va tuttavia sottolineato che, in presenza di dataset misti come quello in esame, l'indice è computabile soltanto sulla componente numerica (pari al 67% delle variabili totali). Questa limitazione non ne inficia l'utilità come strumento di riferimento, ma evidenzia la necessità di affiancarlo con un sistema di misure più articolato, capace di riflettere la complessità strutturale e semantica dei dati.

In quest'ottica è stato sviluppato un framework quadridimensionale di valutazione che integra prospettive statistiche, strutturali e applicative, al fine di fornire un giudizio solido e olistico sulla qualità delle partizioni generate. Le quattro dimensioni individuate, derivate sia dalla teoria statistica sia da esigenze di dominio, sono le seguenti:

- **Balance Score (Equilibrio Strutturale)**

Misura l'equilibrio nella distribuzione delle cardinalità dei cluster, penalizzando configurazioni caratterizzate da classi eccessivamente piccole (<2% del dataset) o sproporzionatamente grandi (>25%). L'indice è calcolato attraverso una combinazione del coefficiente di variazione delle dimensioni e della proporzione di cluster sottosoglia:

$$Balance_Score = \max\left(0, 1 - \frac{CV}{2}\right) \times \left(1 - \frac{n_{small}}{k} \times 0.5\right)$$

Questo criterio assicura che le partizioni siano statisticamente bilanciate e operativamente utilizzabili.

- **Coherence Score (Coerenza Produttiva)**

Valuta la purezza intra-cluster analizzando, per ciascuna variabile categoriale, la frequenza relativa del valore modale. Il risultato finale è una media pesata in funzione della dimensione dei cluster:

$$Coherence_var = \sum_i \left(\frac{max_count_i}{cluster_size_i} \times weight_i \right)$$

L'indice è particolarmente rilevante in ambito industriale, poiché cluster con elevata coerenza interna facilitano interpretazioni chiare e traducono più agevolmente la segmentazione in azioni operative.



- **Separation Score (Separabilità Statistica)**

Misura la forza dell'associazione tra appartenenza al cluster e distribuzione delle variabili tramite il V di Cramér, derivato dal test Chi-quadrato:

$$V_{Cramér} = \sqrt{\frac{\chi^2}{n \times \min(r - 1, c - 1)}}$$

Valori elevati indicano che la variabile in questione contribuisce in modo statisticamente significativo a differenziare i cluster, rafforzando così l'interpretabilità delle partizioni.

- **Business Relevance Score (Rilevanza Applicativa)**

Dimensione specificamente introdotta per garantire l'aderenza dell'analisi alle esigenze industriali. Un cluster è considerato "business-relevant" se soddisfa tre criteri:

- dimensione $\geq 1\%$ del dataset,
- coerenza media $\geq 60\%$,
- almeno tre attributi dominanti con purezza $\geq 50\%$.

Questo punteggio evita che vengano privilegiate partizioni statisticamente eleganti ma scarsamente significative sul piano operativo.

Le quattro dimensioni sono state combinate in un indice sintetico, il Clustering Quality Score (CQS), attraverso pesi calibrati secondo le priorità del dominio ceramico-industriale:

$$CQS = (0,15 \times Balance) + (0,35 \times Coherence) + (0,25 \times Separation) + (0,25 \times Bus. Rel.)$$

Il peso più elevato attribuito alla coerenza produttiva (35%) riflette l'esigenza primaria di disporre di cluster omogenei e ben interpretabili, in grado di supportare decisioni industriali concrete.

Il CQS è stato interpretato secondo una scala qualitativa a cinque livelli:

- Eccellente ($\geq 0,80$),
- Molto Buono ($0,70-0,80$),
- Buono ($0,60-0,70$),
- Accettabile ($0,50-0,60$),
- Insufficiente ($< 0,50$).

In questo modo, il sistema di validazione non si limita a riprodurre la logica geometrico-statistica del Silhouette Score, ma la arricchisce con prospettive strutturali e applicative, traducendo i risultati in criteri tangibili di fruibilità industriale.


L'impianto metodologico così definito consente non solo di individuare un numero ottimale di cluster, ma soprattutto di validarne la qualità con criteri convergenti e trasferibili, assicurando robustezza, interpretabilità e utilizzabilità industriale dei risultati, in piena coerenza con gli obiettivi scientifici e applicativi dell'attività.

3.RISULTATI

3.1 Performance algoritmiche

L'implementazione dell'algoritmo K-Prototypes è stata progettata e condotta con l'obiettivo di verificare la capacità del modello di individuare strutture latenti all'interno del portafoglio prodotti, garantendo al contempo stabilità delle soluzioni e coerenza rispetto agli obiettivi progettuali prefissati. La fase di ottimizzazione parametrica ha richiesto un approccio sistematico, caratterizzato dall'esplorazione completa dell'intervallo di valori di k compreso tra 10 e 25. Per ciascun valore di k sono state condotte 15 inizializzazioni multiple ($n_{init}=15$) in fase esplorativa, utilizzando sia il metodo di Cao che quello di Huang, al fine di contenere la variabilità dovuta alla randomizzazione e verificare l'impatto dei diversi schemi di inizializzazione sulla convergenza.

La selezione del numero ottimale di cluster è stata effettuata sulla base del Silhouette Score calcolato sulle variabili numeriche, assunto come indice di riferimento per la fase di ricerca esplorativa. I risultati hanno evidenziato una crescita progressiva del Silhouette al crescere di k , con un massimo locale stabile per $k=22$, corrispondente a un valore medio di 0,480.



Tale configurazione è stata confermata da run ripetute con parametri più stringenti ($n_{init}=50$, $max_iter=100$, $random_state=42$), che hanno restituito un Silhouette Score finale pari a 0,493, in linea con la soglia di qualità operativa prefissata ($\geq 0,50$).

Dal punto di vista della robustezza computazionale, il modello ha dimostrato un comportamento stabile: la convergenza è stata raggiunta in un numero ridotto di iterazioni (in media 5–7), con bassa variabilità dei risultati tra le diverse inizializzazioni. La riproducibilità è stata assicurata dall'uso di seed controllati e dall'automatizzazione dell'intero flusso operativo, che ha permesso di verificare la coerenza dei risultati su più esecuzioni indipendenti.

Un elemento di rilievo riguarda il confronto con la baseline progettuale. Il target iniziale prevedeva l'individuazione di un numero di cluster compreso tra 15 e 20, con l'uso dell'Accuracy Rate come metrica di valutazione. L'attività svolta ha invece portato all'identificazione di 22 cluster, superando quindi il limite superiore della baseline. Tuttavia, questa deviazione non costituisce una criticità, bensì un'evidenza della maggiore granularità necessaria per rappresentare adeguatamente la complessità del portafoglio prodotti. Analogamente, la sostituzione dell'Accuracy Rate con metriche intrinseche quali il Silhouette Score e il Clustering Quality Score (CQS) ha consentito di raggiungere un livello di validazione molto più solido sul piano scientifico, migliorando la significatività complessiva delle partizioni identificate.

In sintesi, le performance algoritmiche hanno dimostrato che la metodologia implementata è in grado di:

- raggiungere valori di Silhouette coerenti con i target di accettabilità;
- garantire stabilità e riproducibilità dei risultati;
- identificare un numero di cluster superiore al previsto, ma statisticamente e operativamente giustificato dalla complessità del dominio di applicazione.

3.2 Valutazione multidimensionale della qualità

La validazione di un modello di clustering non supervisionato non può limitarsi a un unico indice, poiché ciascun criterio cattura aspetti parziali della qualità delle partizioni. Per questo motivo, accanto al Silhouette Score – assunto come indicatore primario e utilizzato per guidare l'ottimizzazione del numero di cluster – è stato costruito un framework di valutazione multidimensionale, capace di integrare prospettive statistiche, strutturali e applicative.

L'obiettivo di tale framework è duplice: da un lato garantire che i cluster risultino statisticamente consistenti e ben differenziati; dall'altro assicurare che essi siano operativamente rilevanti, ovvero traducibili in conoscenza utile per la gestione industriale del portafoglio prodotti. Questo approccio consente di superare la dipendenza da metriche uniche, talvolta riduttive, introducendo una visione olistica che valorizza contemporaneamente equilibrio distributivo, coerenza interna, separabilità statistica e rilevanza applicativa.

I quattro indici introdotti sono stati definiti come segue:

- Balance Score (Equilibrio Strutturale): garantisce che i cluster non presentino sbilanciamenti eccessivi di numerosità, penalizzando configurazioni dominate da poche classi o frammentate in micro-gruppi privi di significatività.
- Coherence Score (Coerenza Produttiva): misura la purezza interna dei cluster valutando la presenza di attributi dominanti, condizione indispensabile per assicurare interpretabilità e traducibilità in termini operativi.

- Separation Score (Separabilità Statistica): quantifica la capacità delle variabili di discriminare i cluster attraverso test statistici di associazione, rafforzando la solidità delle differenze rilevate.
- Business Relevance Score (Rilevanza Applicativa): assicura che i cluster siano effettivamente utilizzabili in contesto industriale, introducendo criteri minimi di dimensione, coerenza e presenza di attributi discriminanti.

La combinazione di queste quattro dimensioni ha prodotto un indice sintetico, il Clustering Quality Score (CQS), costruito attraverso pesi calibrati sulle priorità del dominio ceramico. I risultati ottenuti confermano la validità del framework:

- Balance Score = 0,811, a testimonianza di una distribuzione equilibrata tra i 22 cluster, con un solo cluster al di sotto della soglia minima del 2%.
- Coherence Score = 0,721, valore che denota un'elevata purezza interna, particolarmente marcata per le variabili "Dimensione" (98,4%) e "Spessore" (85,9%).
- Separation Score = 0,623, che riflette associazioni statisticamente significative tra cluster e variabili, con valori molto elevati per "Dimensione" (0,975) e "Scivolosità R" (0,774).
- Business Relevance Score = 1,000, evidenziando che tutti i cluster individuati superano i criteri di applicabilità industriale stabiliti.

L'indice composito CQS ha raggiunto il valore di 0,780, corrispondente alla categoria qualitativa "Molto Buono", a conferma della solidità e della rilevanza delle partizioni ottenute.

SISTEMA AVANZATO DI VALUTAZIONE CLUSTERING		
BILANCIAMENTO CLUSTER Numero cluster: 22 Dimensione media: 602 prodotti Coeff. variazione: 0.339 Cluster piccoli (<2%): 1 Cluster grandi (>25%): 0 BALANCE SCORE: 0.811 COERENZA PRODUTTIVA Forma: 0.508 Dimensione: 0.984 Spessore: 0.859 Scivolosità R: 0.829 Effetto: 0.470 Colore: 0.675 COHERENCE SCORE: 0.721	SEPARABILITÀ STATISTICA Forma: Cramér's V = 0.349 *** Dimensione: Cramér's V = 0.975 *** Spessore: Cramér's V = 0.756 *** Scivolosità R: Cramér's V = 0.774 *** Effetto: Cramér's V = 0.232 *** Colore: Cramér's V = 0.655 *** SEPARATION SCORE: 0.623 RILEVANZA BUSINESS BUSINESS RELEVANCE SCORE: 1.000	VALUTAZIONE COMPLESSIVA Balance Score: 0.811 (peso: 15%) Coherence Score: 0.721 (peso: 35%) Separation Score: 0.623 (peso: 25%) Business Score: 1.000 (peso: 25%) CLUSTERING QUALITY SCORE: 0.780 QUALITÀ: MOLTO BUONO ★★★★★ RACCOMANDAZIONE: Ottimo risultato, procedi con implementazione.

3.3 Caratterizzazione dei cluster e profili produttivi

L'analisi dei cluster individuati non si è limitata alla misurazione della loro qualità numerica e statistica, ma ha mirato a ricostruire i profili produttivi sottostanti, traducendo le partizioni in informazioni direttamente interpretabili e utilizzabili nel contesto industriale. L'approccio seguito ha avuto come obiettivo quello di coniugare rigore metodologico e rilevanza operativa: ogni cluster è stato quindi letto non

soltanto come aggregazione di osservazioni statistiche, ma come tipologia produttiva coerente, dotata di caratteristiche distintive e potenzialmente rilevanti per decisioni strategiche in ambito manifatturiero e commerciale.

Il principio guida è stato quello della parsimonia interpretativa: attribuire a ciascun cluster un set di descrittori chiave, sufficiente a spiegare la coesione interna e la separazione rispetto alle altre classi, evitando però ridondanze o descrizioni eccessivamente frammentate. L'analisi ha evidenziato come variabili quali dimensione, spessore e prestazioni antiscivolo rappresentino i driver maggiormente discriminanti, mentre attributi come colore ed effetto superficiale contribuiscono in maniera più sfumata a definire la specificità dei gruppi. Questa gerarchia di importanza riflette sia la natura tecnica del prodotto ceramico sia le preferenze di mercato osservate nel periodo 2017–2024.

La caratterizzazione è stata ulteriormente rafforzata dall'utilizzo di metriche interne di coerenza, che hanno permesso di individuare, per ciascun cluster, gli attributi dominanti con livelli di purezza superiori al 70%. In tal modo, i cluster risultano non solo statisticamente validi, ma anche descrivibili attraverso etichette sintetiche ("medio + chiaro", "rettangolare + cemento", ecc.) che ne facilitano l'utilizzo nei sistemi di reportistica e supporto decisionale.

Alcuni esempi concreti aiutano a comprendere la natura delle partizioni individuate:

- Cluster 3 (635 prodotti, 4,8% del totale): caratterizzato da prodotti di dimensione media, spessore 9mm, con prestazioni ANTISLIP e colorazioni prevalentemente chiare. L'elevata purezza di queste caratteristiche rende il cluster facilmente riconoscibile e utilizzabile come segmento omogeneo.
- Cluster 21 (571 prodotti, 4,3% del totale): connotato da prevalenza di forma rettangolare, dimensione media, spessore 8mm e forte rappresentanza dell'effetto cemento. Questo cluster mostra un profilo tipologico di immediato interesse per il mercato, con caratteristiche distintive e coerenti.
- Cluster 13 (492 prodotti, 3,7% del totale): rappresenta una nicchia caratterizzata da spessori ridotti e colori variegati, con una produzione media significativamente inferiore rispetto ad altri cluster, suggerendo potenziali valutazioni strategiche in termini di razionalizzazione di gamma.

L'analisi congiunta di questi profili conferma che i cluster non costituiscono semplici aggregati numerici, ma riflettono strutture produttive effettive e interpretabili, con impatto diretto sulla gestione del portafoglio. Tale caratterizzazione consente non solo di leggere lo stato attuale del portafoglio prodotti, ma anche di predisporre strumenti previsionali e scenari evolutivi, in cui la domanda può essere analizzata non per singole variabili isolate, ma per combinazioni complesse di attributi.



SusTainable dAta-dRiven manufacTuring

Accordo Innovazione DM 31/12/2021

Prog. n. F/310087/01-05/X56

Cluster 0 (797 prod., 6.0%):

INTERPRETABILE

Forma: LISTELLO (48.3%)
Dimensione: PICCOLO (100.0%)
Spessore: 8mm (85.9%)
Scivolosità R: ANTISLIP (70.5%)
Effetto: PIETRA (55.8%)
Colore: CHIARO (54.0%)

Cluster 5 (477 prod., 3.6%):

INTERPRETABILE

Forma: RETTANGOLARE (59.7%)
Dimensione: GRANDE (100.0%)
Spessore: 9mm (85.7%)
Scivolosità R: ANTISLIP (72.7%)
Effetto: CEMENTO (44.2%)
Colore: SCURO (85.5%)

Cluster 10 (464 prod., 3.5%):

INTERPRETABILE

Forma: QUADRATO (48.7%)
Dimensione: PICCOLO (100.0%)
Spessore: 8mm (87.1%)
Scivolosità R: ANTISLIP (67.9%)
Effetto: PIETRA (50.2%)
Colore: SCURO (57.1%)

Cluster 15 (979 prod., 7.4%):

INTERPRETABILE

Forma: QUADRATO (50.6%)
Dimensione: MEDIO (100.0%)
Spessore: 9mm (79.3%)
Scivolosità R: ANTISLIP (100.0%)
Effetto: PIETRA (48.7%)
Colore: SCURO (89.5%)

Cluster 20 (243 prod., 1.8%):

INTERPRETABILE

Forma: RETTANGOLARE (47.3%)
Dimensione: MEDIO (60.1%)
Spessore: 8mm (60.1%)
Scivolosità R: NPD (100.0%)
Effetto: CEMENTO (36.6%)
Colore: SCURO (85.6%)

Cluster 1 (738 prod., 5.6%):

INTERPRETABILE

Forma: RETTANGOLARE (57.9%)
Dimensione: GRANDE (100.0%)
Spessore: 9mm (77.4%)
Scivolosità R: ANTISLIP (100.0%)
Effetto: PIETRA (50.9%)
Colore: MEDIO (51.5%)

Cluster 6 (1077 prod., 8.1%):

INTERPRETABILE

Forma: QUADRATO (51.2%)
Dimensione: MEDIO (100.0%)
Spessore: 9mm (60.1%)
Scivolosità R: ANTISLIP (100.0%)
Effetto: PIETRA (48.0%)
Colore: MEDIO (83.8%)

Cluster 11 (538 prod., 4.1%):

INTERPRETABILE

Forma: QUADRATO (42.2%)
Dimensione: MEDIO (100.0%)
Spessore: 9mm (97.4%)
Scivolosità R: R9 (100.0%)
Effetto: PIETRA (31.6%)
Colore: CHIARO (62.1%)

Cluster 16 (385 prod., 2.9%):

INTERPRETABILE

Forma: LISTELLO (40.0%)
Dimensione: MEDIO (100.0%)
Spessore: 7mm (100.0%)
Scivolosità R: NPD (69.4%)
Effetto: CEMENTO (30.9%)
Colore: CHIARO (60.8%)

Cluster 21 (571 prod., 4.3%):

INTERPRETABILE

Forma: RETTANGOLARE (51.1%)
Dimensione: MEDIO (99.8%)
Spessore: 8mm (83.4%)
Scivolosità R: NPD (63.4%)
Effetto: CEMENTO (39.8%)
Colore: CHIARO (52.2%)

Cluster 2 (570 prod., 4.3%):

INTERPRETABILE

Forma: QUADRATO (48.6%)
Dimensione: PICCOLO (100.0%)
Spessore: 8mm (75.4%)
Scivolosità R: NPD (100.0%)
Effetto: PIETRA (42.3%)
Colore: VARI (54.6%)

Cluster 7 (860 prod., 6.5%):

INTERPRETABILE

Forma: LISTELLO (47.1%)
Dimensione: PICCOLO (100.0%)
Spessore: 9mm (96.9%)
Scivolosità R: ANTISLIP (65.7%)
Effetto: PIETRA (48.0%)
Colore: CHIARO (56.7%)

Cluster 12 (512 prod., 3.9%):

INTERPRETABILE

Forma: LISTELLO (44.3%)
Dimensione: PICCOLO (100.0%)
Spessore: 9mm (97.7%)
Scivolosità R: ANTISLIP (63.5%)
Effetto: PIETRA (68.6%)
Colore: SCURO (77.7%)

Cluster 17 (382 prod., 2.9%):

INTERPRETABILE

Forma: QUADRATO (56.8%)
Dimensione: MEDIO (87.2%)
Spessore: 7mm (100.0%)
Scivolosità R: ANTISLIP (66.2%)
Effetto: CEMENTO (48.7%)
Colore: MEDIO (52.9%)

Cluster 3 (635 prod., 4.8%):

INTERPRETABILE

Forma: QUADRATO (48.3%)
Dimensione: MEDIO (100.0%)
Spessore: 9mm (100.0%)
Scivolosità R: ANTISLIP (100.0%)
Effetto: PIETRA (53.7%)
Colore: CHIARO (100.0%)

Cluster 8 (725 prod., 5.5%):

INTERPRETABILE

Forma: LISTELLO (53.8%)
Dimensione: PICCOLO (100.0%)
Spessore: 8mm (63.4%)
Scivolosità R: NPD (100.0%)
Effetto: PIETRA (45.1%)
Colore: CHIARO (56.7%)

Cluster 13 (494 prod., 3.7%):

INTERPRETABILE

Forma: RETTANGOLARE (65.4%)
Dimensione: GRANDE (100.0%)
Spessore: 9mm (96.6%)
Scivolosità R: NPD (56.9%)
Effetto: CEMENTO (32.2%)
Colore: CHIARO (48.4%)

Cluster 18 (692 prod., 5.2%):

INTERPRETABILE

Forma: QUADRATO (49.4%)
Dimensione: MEDIO (100.0%)
Spessore: 9mm (98.6%)
Scivolosità R: NPD (100.0%)
Effetto: CEMENTO (38.2%)
Colore: CHIARO (54.2%)

Cluster 4 (418 prod., 3.2%):

INTERPRETABILE

Forma: QUADRATO (48.1%)
Dimensione: PICCOLO (88.0%)
Spessore: 7mm (100.0%)
Scivolosità R: NPD (79.4%)
Effetto: DECORI (37.6%)
Colore: VARI (55.0%)

Cluster 9 (724 prod., 5.5%):

INTERPRETABILE

Forma: QUADRATO (44.1%)
Dimensione: MEDIO (99.7%)
Spessore: 9mm (98.2%)
Scivolosità R: NPD (50.4%)
Effetto: CEMENTO (38.0%)
Colore: SCURO (88.1%)

Cluster 14 (507 prod., 3.8%):

INTERPRETABILE

Forma: RETTANGOLARE (55.8%)
Dimensione: MEDIO (96.6%)
Spessore: 8mm (72.6%)
Scivolosità R: ANTISLIP (68.8%)
Effetto: CEMENTO (49.1%)
Colore: SCURO (84.8%)

Cluster 19 (463 prod., 3.5%):

INTERPRETABILE

Forma: RETTANGOLARE (60.7%)
Dimensione: MEDIO (100.0%)
Spessore: 8mm (100.0%)
Scivolosità R: ANTISLIP (100.0%)
Effetto: PIETRA (49.5%)
Colore: MEDIO (53.3%)

3.5 Analisi temporale e correlazioni produttive

L'analisi temporale dei dati di vendita relativi al periodo 2017–2024 ha rappresentato un passaggio cruciale per valutare la solidità e la rilevanza operativa delle partizioni individuate dal modello. Il clustering consente di fotografare la struttura latente del portafoglio prodotti in un dato istante, mentre l'aggancio ex-post ai trend di mercato permette di validarne la dinamicità e di comprendere come le caratteristiche distintive di ciascun cluster abbiano inciso sul successo commerciale lungo l'asse temporale. In questo senso, l'integrazione tra analisi strutturale e serie storiche di vendita trasforma il modello in uno strumento non solo descrittivo, ma anche di supporto ad analisi di tipo predittivo e strategico, capace di evidenziare relazioni non lineari tra configurazioni di attributi e performance di mercato.

I risultati hanno evidenziato una notevole variabilità tra i cluster. Alcuni cluster si sono affermati come poli produttivi dominanti, concentrando una quota significativa dei volumi totali analizzati: il Cluster 21 ha raggiunto 1.110,6 mq/prodotto (per un totale di 634.155 mq), seguito dal Cluster 3 con 981,0 mq/prodotto (622.933 mq complessivi) e dal Cluster 14 con 874,5 mq/prodotto (443.362 mq complessivi). Questi segmenti si distinguono non solo per la dimensione quantitativa, ma anche per la coerenza interna delle



SusTainable dAta-dRiven manufacTuring

Accordo Innovazione DM 31/12/2021


Prog. n. F/310087/01-05/X56

caratteristiche che li definiscono, a conferma della capacità del modello di individuare configurazioni produttive ad alta rilevanza commerciale.

Parallelamente, sono emersi cluster di nicchia, come il Cluster 13, con una media di 64,6 mq/prodotto (31.936 mq totali) che, pur non incidendo in maniera significativa sui volumi globali, forniscono indicazioni preziose per strategie mirate di differenziazione o per politiche di posizionamento in segmenti specifici del mercato. La distribuzione complessiva dei volumi, pari a 5.561.557 mq nel periodo di osservazione, riflette così un equilibrio tra cluster ad alta intensità produttiva e cluster marginali ma potenzialmente strategici.

Un ulteriore elemento di interesse emerso dall'analisi riguarda la non linearità delle correlazioni tra singoli attributi e performance aggregate. Mentre l'analisi univariata dei fattori isolati (es. effetto estetico, colore, spessore) restituisce solo tendenze parziali, l'approccio multivariato evidenzia come siano le combinazioni complesse di caratteristiche a determinare i reali trend di mercato. In tal modo, diventa possibile riconoscere interazioni sinergiche tra attributi che, presi singolarmente, non mostrerebbero un impatto significativo, ma che insieme configurano prodotti ad elevata competitività.

L'analisi temporale, dunque, non solo ha validato la robustezza delle partizioni ottenute, ma ha anche permesso di ricostruire la traiettoria evolutiva dei cluster lungo l'intero periodo osservato, evidenziando quali configurazioni hanno acquisito centralità e quali, invece, hanno mantenuto una presenza marginale. Queste informazioni risultano particolarmente rilevanti in ottica strategica, poiché consentono di orientare sia le scelte di ottimizzazione del portafoglio che eventuali interventi di pricing differenziato e di razionalizzazione produttiva.



3.6 Confronto analitico multivariato vs univariato

Un aspetto di particolare rilevanza emerso nell'indagine riguarda il confronto tra l'analisi univariata delle caratteristiche dei prodotti e l'approccio multivariato adottato attraverso il clustering. L'analisi univariata, pur essendo metodologicamente semplice e di immediata interpretazione, presenta un limite intrinseco: ciascun attributo viene considerato isolatamente, presupponendo che il suo contributo al comportamento di mercato o alla performance produttiva possa essere valutato indipendentemente dagli altri fattori. Questa impostazione riduttiva tende a trascurare le interazioni tra caratteristiche, restituendo una rappresentazione parziale e spesso fuorviante delle dinamiche sottostanti.

L'analisi multivariata, al contrario, si fonda sull'idea che le proprietà di un prodotto non possano essere comprese appieno se analizzate separatamente. Il valore informativo scaturisce dall'interazione tra dimensioni estetiche, strutturali e prestazionali, che, combinate, delineano configurazioni distintive non riconducibili alla somma dei singoli effetti. In questo contesto, il clustering mediante K-Prototypes ha permesso di individuare pattern emergenti che non sarebbero stati rilevabili con un'analisi per variabili isolate.

I risultati hanno mostrato, ad esempio, che la crescita della domanda in specifici segmenti non è attribuibile unicamente a una caratteristica predominante (come il colore chiaro o l'effetto pietra), ma piuttosto alla combinazione sinergica di più attributi, quali il formato rettangolare medio con finitura cemento e spessore ridotto. Analogamente, cluster di nicchia hanno evidenziato come configurazioni apparentemente marginali – quando analizzate singolarmente – assumano rilevanza significativa se considerate nella loro interazione con altri attributi.

Tali evidenze confermano che l'approccio multivariato non solo arricchisce l'interpretazione dei dati, ma fornisce strumenti più solidi per la pianificazione strategica: la conoscenza dei cluster permette infatti di comprendere quali combinazioni di caratteristiche guidano la preferenza dei clienti e quali segmenti presentano potenzialità di crescita o, al contrario, segnali di declino.

Il confronto metodologico mette così in luce la natura complementare ma non equivalente dei due approcci: l'analisi univariata conserva utilità in fase esplorativa o di sintesi preliminare, mentre l'analisi multivariata rappresenta lo strumento necessario per cogliere le relazioni complesse e non lineari che governano i fenomeni industriali e di mercato.

3.7 Deliverable generati

Un elemento di rilevanza operativa del lavoro svolto consiste nella produzione sistematica di deliverable strutturati, concepiti non come meri risultati tecnici, ma come strumenti di trasferimento diretto del valore al contesto industriale. La logica di generazione degli output ha seguito un principio di usabilità immediata, garantendo che ciascun documento o file prodotto rispondesse a un preciso fabbisogno decisionale.

Il dataset completo con assegnazioni di cluster per ciascuno dei 13.251 prodotti analizzati rappresenta la base informativa per l'integrazione delle conoscenze nei sistemi gestionali aziendali: grazie a tale archivio è possibile collegare in maniera trasparente ogni articolo al proprio segmento di appartenenza, favorendo processi di razionalizzazione del portafoglio, pianificazione produttiva e analisi dei trend di vendita.

I profili cluster dettagliati, sintetizzati in tabelle che riportano le caratteristiche dominanti, svolgono una funzione esplicativa fondamentale: essi consentono di leggere i segmenti individuati in termini operativi e di riconoscere immediatamente quali attributi definiscono la loro identità. Tali profili costituiscono uno strumento di comunicazione interna tra le funzioni aziendali, facilitando il dialogo tra le aree di marketing, design e produzione.

Il file dedicato alle metriche di valutazione multidimensionale (Clustering Evaluation Scores) fornisce un cruscotto diagnostico per la validazione metodologica, permettendo di monitorare nel tempo la robustezza e la coerenza delle soluzioni. Questo deliverable garantisce che il modello non sia una soluzione statica, ma un sistema continuamente verificabile e aggiornabile secondo logiche di manutenzione evolutiva.

Particolare valore assume la dashboard visiva, composta da rappresentazioni grafiche e analisi comparative, che traduce la complessità metodologica in strumenti di facile lettura per i decision maker. Attraverso grafici e sintesi numeriche, i cluster diventano entità immediatamente interpretabili e confrontabili, con impatto diretto sulla capacità dell'impresa di orientare le scelte strategiche.

In questo modo, i deliverable prodotti non costituiscono un semplice corredo documentale, ma si configurano come veri e propri strumenti di trasferimento tecnologico, capaci di innestarsi nei processi decisionali e di generare impatto tangibile sull'efficienza e sulla competitività aziendale.

4.DISCUSSIONE E CONCLUSIONI

L'attività sviluppata nell'ambito dell'OR 6.8 ha affrontato con rigore e sistematicità una criticità metodologica di grande rilevanza nell'analisi di portafogli di prodotto complessi, caratterizzati da un'elevata eterogeneità di attributi. Il lavoro ha permesso non solo di conseguire gli obiettivi numerici fissati in fase di proposta, ma di rafforzarli con un impianto scientifico più solido e aderente alla natura del problema. La sostituzione dell'Accuracy Rate, originariamente previsto come KPI di valutazione, con il Silhouette Score e con un framework quadridimensionale di validazione ha rappresentato il primo passaggio cruciale: in questo modo, la valutazione dei cluster si è fondata non su un indicatore improprio, ma su un insieme coerente di metriche statistiche e operative, capaci di cogliere da più prospettive la qualità delle partizioni individuate. Parallelamente, la costruzione e il preprocessing del dataset hanno costituito un secondo snodo fondamentale. L'analisi di oltre 13.000 prodotti finiti, ciascuno descritto da attributi estetici, strutturali e prestazionali, ha richiesto un lavoro metodico di selezione e codifica delle variabili, mirato a preservarne il significato semantico e a ridurre il rumore informativo. La scelta di escludere i dati di performance commerciale dalla fase di clustering, per poi riagganciarli ex post, si è rivelata particolarmente efficace: da un lato ha garantito neutralità e oggettività nel processo di segmentazione, dall'altro ha consentito di verificare a posteriori la rilevanza operativa dei cluster rispetto ai trend di mercato, rafforzando il legame tra rigore metodologico e utilità applicativa. Sul piano algoritmico, l'adozione del K-Prototypes si è dimostrata la scelta più coerente con la natura mista dei dati, in quanto ha permesso di trattare simultaneamente variabili numeriche e categoriali senza dover ricorrere a trasformazioni arbitrarie e potenzialmente distorsive. L'ottimizzazione sistematica dei parametri, condotta attraverso esplorazioni estese del numero di cluster, repliche multiple e diversi schemi di inizializzazione, ha prodotto partizioni stabili, riproducibili e statisticamente significative, rispondendo ai requisiti di robustezza

richiesti da un progetto di ricerca industriale applicata. L'avanzamento metodologico più rilevante è stato però rappresentato dal sistema di valutazione multidimensionale, costruito per superare i limiti del Silhouette Score e per restituire una misura olistica della qualità delle partizioni. Gli indici di equilibrio, coerenza, separabilità e rilevanza industriale hanno reso possibile una diagnosi completa e, soprattutto, hanno permesso di tradurre i risultati in criteri di fruibilità immediata. L'indice sintetico CQS, pari a 0,780 e collocato nella fascia "Molto Buono", ha confermato che i cluster generati sono al tempo stesso statisticamente validi e concretamente utilizzabili nei processi decisionali aziendali. L'analisi dei 22 cluster individuati, un numero leggermente superiore al range inizialmente ipotizzato, ha ulteriormente dimostrato la capacità del modello di restituire una rappresentazione più granulare e realistica del portafoglio prodotti. Le configurazioni emerse evidenziano come la domanda di mercato non dipenda da singole caratteristiche isolate, ma dall'interazione di più fattori estetici, strutturali e funzionali. Questa evidenza, confermata anche dall'analisi temporale delle vendite 2017–2024, sottolinea la superiorità dell'approccio multivariato rispetto a quello univariato, fornendo strumenti di lettura più vicini alla complessità reale del mercato ceramico. Un ulteriore punto di forza dell'attività risiede nei deliverable prodotti, concepiti non come semplici risultati tecnici, ma come strumenti operativi a supporto dei processi aziendali. Dataset arricchiti con assegnazioni di cluster, profili descrittivi dei segmenti, metriche di validazione, dashboard visive e raccomandazioni implementative hanno trasformato l'analisi in un patrimonio utilizzabile da diverse funzioni aziendali — dal marketing al design, dalla pianificazione alla produzione — contribuendo a rendere le scelte più consapevoli e basate su evidenze oggettive. In definitiva, l'attività svolta nell'OR 6.8 ha conseguito risultati che vanno ben oltre il mero raggiungimento degli obiettivi numerici iniziali. Ha introdotto un salto metodologico sostanziale con un sistema di validazione rigoroso, trasformando un dataset frammentato in una base informativa strutturata e interpretabile, e implementando un modello di clustering robusto, stabile e pienamente trasferibile. Ma soprattutto, ha reso l'analisi un vero e proprio strumento di trasformazione digitale, capace di integrare la gestione dei dati di prodotto nei processi di pianificazione, produzione e sviluppo strategico, in linea con le finalità del progetto e con la visione di un'Industria 4.0 orientata all'intelligenza, all'efficienza e alla sostenibilità.